

Intelligenza Artificiale Generativa

Dalla storia alle architetture, dai chatbot ai generatori di immagini, video e audio. Stato dell'arte secondo i benchmark ARENA, raccolta dei migliori prompt e prospettive verso il 2027 e oltre.

Documento redatto su richiesta e basato su ricerca web verificata.

Dati aggiornati a giugno 2026. Tutte le affermazioni fattuali sono corredate da riferimenti numerici alle fonti, elencate nella bibliografia finale.

Indice

Premessa	3
1 • Le fondamenta: cos'è (e cosa non è) l'IA generativa	4
1.1 Generativa contro discriminativa: la vera linea di confine	4
1.2 Un chiarimento necessario: anche il chatbot è IA generativa	4
2 • Storia ed evoluzione	6
2.1 Le radici (1950–2012)	6
2.2 Il 2014 e le GAN: la svolta per le immagini	6
2.3 Autoencoder variazionali e modelli di diffusione	6
2.4 Il 2017 e i Transformer: la svolta per il linguaggio	6
2.5 Dall'esplosione del 2022 a oggi	7
3 • Chatbot e generatori visivi: perché sono diversi	8
3.1 Il modello autoregressivo (testo)	8
3.2 Il modello a diffusione (immagini e video)	8
3.3 La convergenza in atto	8
4 • Stato dell'arte 2026: gli strumenti	10
4.1 Cosa sono e come funzionano i benchmark ARENA	10
4.2 Testo e chatbot	10
4.3 Generazione di immagini	10
4.4 Generazione di video	11
4.5 Generazione di audio: musica e voce	12
4.6 Il nodo trasversale: copyright e licenze	12
5 • Sviluppi futuri e ottimizzazioni: il 2027 e oltre	14
Conclusioni	16
Appendice A • I migliori prompt per le immagini	17
Appendice B • I migliori prompt per i video	19
Bibliografia e fonti	21

▪ Premessa

L'espressione "intelligenza artificiale" indica oggi due famiglie tecnologiche profondamente diverse, spesso confuse perché convivono negli stessi prodotti. Da un lato c'è l'IA che *riconosce, classifica e prevede* (un filtro antispam, un sistema di visione che distingue un pezzo conforme da uno difettoso, un motore di raccomandazione). Dall'altro c'è l'IA che *crea contenuti nuovi*: testo, immagini, video, suono. È quest'ultima — l'IA generativa — il cuore di questo documento.

L'obiettivo è ricostruire, partendo dalla storia, da dove nasce la distinzione tra IA generativa e non generativa, chiarire perché un chatbot a domanda-risposta e un generatore di immagini o video, pur appartenendo entrambi al mondo generativo, funzionano in modo radicalmente diverso, e fotografare lo stato dell'arte degli strumenti disponibili a metà 2026 secondo i benchmark più seguiti, a partire dalle "arene" a voto umano. Chiudono il documento due appendici operative con i migliori schemi di prompt per immagini e video, e un capitolo sulle prospettive verso il 2027.

NOTA DI METODO

Questo è un campo che cambia di settimana in settimana. I numeri delle classifiche sono **istantanee** riferite a una data e a una specifica piattaforma di valutazione: piattaforme diverse usano bacini di voti diversi e quindi punteggi e ordini non coincidono. Dove possibile è indicata la data del dato. Le affermazioni fattuali rimandano alle fonti con un numero in apice, es.¹; l'elenco completo è in fondo. Nulla è stato inventato: dove le fonti divergono, la divergenza è segnalata.

1 Le fondamenta: cos'è (e cosa non è) l'IA generativa

1.1 Generativa contro discriminativa: la vera linea di confine

In informatica la distinzione tecnicamente corretta non è tra "IA che risponde" e "IA che disegna", ma tra **modelli discriminativi** e **modelli generativi**. Un modello discriminativo impara il *confine* tra categorie: dato un input, decide a quale classe appartiene o quale valore prevedere. Non produce contenuto nuovo, classifica o stima.³ Sono discriminativi i classificatori di immagini ("cane" o "gatto"), i filtri antispam, i sistemi di rilevamento frodi, la regressione logistica, gli alberi decisionali, le macchine a vettori di supporto (SVM).⁴

Un modello generativo, invece, impara la *distribuzione* dei dati: non si limita a separare le classi, ma coglie come sono fatti i dati e come le loro caratteristiche si relazionano, al punto da poter **generare esempi nuovi** coerenti con quelli visti in addestramento.³ In termini probabilistici, un modello discriminativo stima la probabilità condizionata $p(Y|X)$ — l'etichetta dato l'input — mentre un modello generativo punta alla distribuzione congiunta $p(X, Y)$, cioè a "capire" l'intero spazio dei dati.⁴ È questa capacità che permette a un generatore addestrato su milioni di immagini di cani di produrne di nuove, mai esistite prima.⁵

In sintesi: l'IA **non generativa** (discriminativa) esegue calcoli sull'input — classificare un'immagine, tradurre una frase, prevedere un guasto — mentre l'IA **generativa** produce contenuto inedito: testo, immagini, musica, video.⁵ Storicamente i modelli discriminativi hanno alimentato l'industria per decenni, in modo silenzioso ma capillare; i modelli generativi sono esplosi nell'attenzione pubblica solo dopo il 2022.³

Tabella 1 — Le due famiglie a confronto

Aspetto	IA discriminativa (non generativa)	IA generativa
Obiettivo	Separare, classificare, prevedere	Creare nuovi contenuti
Cosa impara	Il confine tra le classi — $p(Y X)$	La distribuzione dei dati — $p(X,Y)$
Output tipico	Un'etichetta, un punteggio, una previsione	Testo, immagine, audio, video
Esempi	Visione industriale, antispam, scoring, manutenzione predittiva	ChatGPT, Claude, Midjourney, Veo, Suno
Forza	Accuratezza nella classificazione	Creatività e sintesi di contenuto

1.2 Un chiarimento necessario: anche il chatbot è IA generativa

Qui va sciolto un equivoco molto diffuso e legittimo. L'intuizione che un chatbot a domanda-risposta e un generatore di immagini siano "due cose molto diverse" è corretta, ma la differenza **non** è che uno è generativo e l'altro no. Lo sono entrambi: un grande modello linguistico (LLM) come quelli dietro ChatGPT, Claude o Gemini *genera* testo nuovo, paro-

la dopo parola, esattamente come un modello di immagini genera pixel.¹ Il chatbot appartiene a pieno titolo alla famiglia generativa; il suo "contenuto creato" è linguaggio.

La vera differenza tra le due esperienze è di natura **architettonica**, cioè nel *come* il contenuto viene prodotto: gli LLM testuali sono in larga parte modelli *autoregressivi* basati su Transformer (predicono il prossimo elemento di una sequenza), mentre i generatori di immagini e video sono storicamente modelli *a diffusione* (partono dal rumore e lo "ripuliscono" fino all'immagine).² Sono due paradigmi distinti, ed è questo il punto chiave che il capitolo 3 approfondisce. Anticipando: la frontiera del 2026 sta proprio nel *fondere* i due mondi.¹⁰

IN UNA RIGA

Non è "chatbot = non generativo, immagini = generativo". È: **tutti e due sono generativi**, ma costruiti con motori diversi — autoregressivo per il testo, a diffusione per immagini e video — che oggi stanno convergendo.

2 Storia ed evoluzione

Nessuna singola persona ha "inventato" l'IA generativa: il campo è il risultato di contributi successivi. Alan Turing ne pose le basi filosofiche, Frank Rosenblatt costruì la prima rete neurale (il Perceptron, 1958), Ian Goodfellow introdusse le GAN (2014) e il team di Google Brain presentò l'architettura Transformer (2017).¹

2.1 Le radici (1950-2012)

I primi concetti generativi risalgono agli anni '50, con i modelli di Markov nascosti (HMM) e le misture gaussiane. Nel 1966 ELIZA, il celebre programma conversazionale, viene spesso citato come uno dei primi sistemi "generativi" di testo, pur basato su regole.

¹ Per gran parte di questo periodo, però, l'IA che funziona davvero nei prodotti è quella *predittiva*: a partire dal 2012 le reti neurali profonde rivoluzionano la classificazione di immagini e i sistemi di raccomandazione, prevedendo quali video o prodotti interesseranno l'utente.¹ È il regno del discriminativo.

2.2 Il 2014 e le GAN: la svolta per le immagini

La svolta arriva nel 2014, quando Ian Goodfellow e colleghi introducono le **Generative Adversarial Networks (GAN)**. Una GAN mette in competizione due reti neurali: un *generatore*, che crea contenuti, e un *discriminatore*, che cerca di distinguere ciò che è reale da ciò che è generato. Attraverso migliaia di iterazioni, il generatore impara a produrre immagini abbastanza realistiche da ingannare il discriminatore.¹ Le GAN sono tra i primi modelli capaci di immagini fotorealistiche convincenti e aprono di fatto l'era moderna della generazione visiva.¹ Negli anni successivi ne nascono varianti specializzate: DCGAN per stabilizzare l'addestramento, CycleGAN per la traduzione immagine-immagine, StyleGAN per i volti ad alta fedeltà.² È significativo che la generazione moderna nasca dalla *visione*, non dal linguaggio.¹

2.3 Autoencoder variazionali e modelli di diffusione

Quasi in parallelo emergono approcci alternativi. Gli **autoencoder variazionali** (VAE, 2013) di Kingma e Welling mappano i dati in uno spazio latente probabilistico, abilitando interpolazione e generazione fluide.² Soprattutto, intorno al 2015 nascono i **modelli di diffusione**: l'idea è aggiungere progressivamente rumore a un'immagine fino a renderla irriconoscibile, per poi addestrare una rete a invertire il processo, rimuovendo il rumore passo dopo passo e "facendo emergere" un'immagine nuova.¹ Dal 2019 i metodi a diffusione (DDPM, score-based) raggiungono lo stato dell'arte nella generazione di immagini, superando le GAN per qualità e stabilità.² Sono questi i modelli che alimenteranno DALL·E, Stable Diffusion, Imagen.

2.4 Il 2017 e i Transformer: la svolta per il linguaggio

Nel 2017 il paper "Attention Is All You Need" di Vaswani e colleghi introduce l'architettura **Transformer**, basata sul meccanismo di *self-attention*, che gestisce i dati sequenziali in modo molto più efficace delle reti ricorrenti (RNN).² È la base di tutti i grandi modelli

linguistici odierni. Su questa fondazione OpenAI costruisce la serie GPT (Generative Pre-trained Transformer): GPT-2 (2019) mostra di saper generare testo coerente e contestuale, GPT-3 (2020) ne amplia enormemente le capacità.² Da notare una distinzione tecnica: GPT è generativo, mentre BERT — altro modello Transformer del 2018 — è usato in modo prevalentemente discriminativo.² L'architettura, da sola, non determina la categoria: conta come la si usa.

2.5 Dall'esplosione del 2022 a oggi

Tra il 2021 e il 2022 i grandi modelli multimodali (DALL·E, Imagen, Stable Diffusion) combinano Transformer, diffusione e addestramento su scala enorme, estendendo la generazione a immagini, audio, video e codice.² Il lancio pubblico di ChatGPT, a fine 2022, porta l'IA generativa nelle case di tutto il mondo e innesca un'ondata di ricerca e prodotti senza precedenti.¹ Da quel momento la cadenza delle release diventa frenetica: è il contesto in cui si colloca la fotografia dello stato dell'arte del capitolo 4.

Tabella 2 — Tappe essenziali

Anno	Tappa	Significato
1958	Perceptron	Prima rete neurale (Rosenblatt)
1966	ELIZA	Primo programma conversazionale a regole
2013	VAE	Spazio latente probabilistico per la generazione
2014	GAN	Svolta nella generazione di immagini realistiche
2015	Diffusione	Nuovo paradigma: dal rumore all'immagine
2017	Transformer	"Attention Is All You Need": base degli LLM
2019-20	GPT-2 / GPT-3	Generazione di testo coerente su larga scala
2021-22	DALL·E, Stable Diffusion	Generazione visiva multimodale di massa
2022	ChatGPT	L'IA generativa diventa fenomeno globale

3 Chatbot e generatori visivi: perché sono diversi

Riprendiamo il punto del capitolo 1: chatbot e generatori di immagini sono entrambi generativi, ma usano motori diversi. Vale la pena capire come funzionano, perché spiega anche i loro limiti e i loro punti di forza.

3.1 Il modello autoregressivo (testo)

Un LLM lavora in modo **autoregressivo**: scompone il testo in unità chiamate *token* (parole o frammenti di parola) e, dato tutto ciò che è stato scritto finora, predice il token successivo più probabile; poi lo aggiunge alla sequenza e ripete. La generazione procede così, in modo sequenziale, da sinistra a destra. Il meccanismo di self-attention dei Transformer consente al modello di "pesare" quali parti del contesto sono rilevanti per la prossima parola.² È un processo intrinsecamente *passo-passo* e ad alta intensità di calcolo: a titolo di riferimento, modelli di questa classe hanno raggiunto ordini di grandezza di migliaia di miliardi di parametri.¹

3.2 Il modello a diffusione (immagini e video)

Un generatore di immagini a diffusione segue una logica opposta. Parte da un'immagine di puro rumore casuale e la "denoising" gradualmente — passo dopo passo — guidato dal testo del prompt, fino a far emergere un'immagine coerente.¹ Non c'è un "prossimo pixel": l'intera immagine viene raffinata in parallelo a ogni passo. Per i video, alla dimensione spaziale si aggiunge quella temporale: il modello deve mantenere coerenza tra i fotogrammi (movimento, illuminazione, identità dei soggetti), un problema molto più difficile. È il motivo per cui la generazione video è arrivata alla maturità anni dopo quella delle immagini.

Tabella 3 — Due paradigmi generativi

	Autoregressivo (testo)	Diffusione (immagini/video)
Principio	Predice il prossimo token	Rimuove il rumore passo dopo passo
Direzione	Sequenziale (parola dopo parola)	Raffinamento globale e parallelo
Unità	Token di testo	Pixel / latenti visivi
Sfida principale	Coerenza logica e fattuale	Coerenza spaziale e (per i video) temporale
Esempi	GPT, Claude, Gemini, Grok	Stable Diffusion, Midjourney, Veo, Kling

3.3 La convergenza in atto

La novità più importante del 2026 è che questa separazione si sta dissolvendo. I generatori di immagini di ultima generazione della famiglia "GPT Image" producono le immagini

token per token, in modo simile a come un modello linguistico produce il testo, anziché con la sola diffusione classica.⁸ Sul fronte opposto, modelli nati come linguistici — la linea Gemini di Google — generano ormai immagini che competono con le architetture visive dedicate.¹⁰ Gli osservatori del settore leggono questo come il segnale più forte di tutta la classifica: entro circa dodici mesi la distinzione tra "modello per immagini" e "modello linguistico" rischia di diventare funzionalmente irrilevante, a favore di sistemi unici che *ragionano linguisticamente* mentre *compongono visivamente* in un solo passaggio.¹⁰

4 Stato dell'arte 2026: gli strumenti

4.1 Cosa sono e come funzionano i benchmark ARENA

Quando si parla di "qual è il modello migliore" il riferimento più citato non è un test automatico, ma le **arene a preferenza umana**. La capostipite è la Chatbot Arena nata all'Università di Berkeley (oggi **LMArena**, dopo il rebranding di gennaio 2026), che ha esteso il modello anche a immagini e video.²² Il principio è semplice e robusto: all'utente vengono mostrati gli output di due (o più) modelli *in forma anonima*; l'utente vota quale preferisce; da milioni di confronti a coppie si calcola un punteggio **ELO**, lo stesso sistema usato negli scacchi.²⁰ Eliminando marchi e nomi, l'arena misura la qualità percepita senza il pregiudizio del brand.⁸

Esistono però più "arene" gestite da soggetti diversi — LMArena/Arena.ai, Artificial Analysis, LLM-Stats — ciascuna con il proprio bacino di voti e, in alcuni casi, un sistema di punteggio leggermente diverso (per esempio Artificial Analysis e LMArena usano scale ELO non identiche, e alcune piattaforme adottano TrueSkill).⁶⁸ Per questo i *numeri assoluti* e l'ordine esatto variano da una fonte all'altra: ciò che è solido è il **gruppo di testa**. Le tabelle che seguono riportano la fonte e la data di ciascun dato; vanno lette come istantanee, non come verdetti definitivi.

ATTENZIONE AI NUMERI

Una differenza di 10 punti ELO indica un divario di qualità percepibile; 50 punti, un vantaggio sostanziale.²⁰ Ma confrontare l'ELO di un'arena con quello di un'altra **non ha senso**: sono scale diverse. Confrontate i modelli sempre *all'interno* della stessa classifica.

4.2 Testo e chatbot

Sul fronte testuale, a metà 2026 il vertice è estremamente affollato e sostanzialmente in parità statistica. Nell'istantanea LMArena di maggio 2026, Claude Opus 4.6 guida l'arena testuale con un ELO intorno a 1418, seguito da Gemini 3.1 Pro (~1406) e GPT-5.2 (~1402); poiché gli intervalli di confidenza si sovrappongono, il gruppo di testa va considerato in pareggio tecnico, e la scelta dipende più da costi, conformità ed ecosistema che dal punteggio.²² Più in generale, i modelli di frontiera del 2026 includono la famiglia GPT-5 di OpenAI, le versioni Claude Opus e Sonnet di Anthropic, Gemini 3 Pro di Google, Grok 4 di xAI, oltre a DeepSeek, Qwen, Kimi e GLM sul versante (parzialmente) aperto.²³ Un dato di tendenza: i benchmark tradizionali tipo MMLU sono ormai "saturi" e poco informativi; contano prove più dure come GPQA Diamond, SWE-Bench Verified e i compiti agentici reali.²³

4.3 Generazione di immagini

È l'area più matura. Il gruppo di testa è dominato dalla famiglia **GPT Image** di OpenAI e dalla linea **Nano Banana** di Google (i modelli immagine basati su Gemini), con **Flux 2** di

Black Forest Labs, **Seedream** di ByteDance, **Grok Imagine** di xAI e **Recraft** a completare le posizioni alte.⁶⁹ Nell'istantanea di Artificial Analysis (aprile 2026), in cima alla Text-to-Image Arena c'è GPT Image 2, seguito da GPT Image 1.5 e dai modelli Nano Banana.⁶ Le altre arene (Arena.ai, con oltre 5,2 milioni di voti a fine maggio 2026, e LLM-Stats) confermano lo stesso gruppo di testa con ordini leggermente diversi.⁷⁸

Tabella 4 — Text-to-Image, istantanea Artificial Analysis (aprile 2026). ELO della specifica arena; non confrontabile con altre piattaforme.⁶

#	Modello	Produttore	ELO (arena AA)
1	GPT Image 2 (high)	OpenAI	1338
2	GPT Image 1.5 (high)	OpenAI	1266
3	Nano Banana 2 (Gemini 3.1 Flash Image)	Google	1260
4	Cosmos3-Super-Text2Image	—	1242
5	Nano Banana Pro (Gemini 3 Pro Image)	Google	1219

Sul piano pratico, le sintesi a voto umano indicano GPT Image come la scelta più costante per qualità e per *editing* (modifica guidata di immagini esistenti), particolarmente adatta a materiali di marketing, immagini di prodotto e asset di design; Nano Banana Pro segue molto da vicino ed è naturale per chi è già nell'ecosistema Google; Grok Imagine è un contendente solido con il vantaggio dell'aggancio ai dati in tempo reale di X.⁹ Va ricordato che **Midjourney** resta un riferimento per la resa artistica e stilistica, pur essendo storicamente meno presente in alcune arene per il suo accesso tramite Discord.²⁶ Un'osservazione tecnica importante per la qualità: nei test, i modelli rendono meglio quando il prompt mette *prima* il soggetto e *poi* lo stile (vedi Appendice A).²⁶

4.4 Generazione di video

È l'area più turbolenta. Negli ultimi mesi la classifica si è rimescolata più volte e c'è stato un evento di rilievo: **OpenAI ha dismesso Sora**. L'app è stata chiusa intorno al 24 marzo 2026, dopo un calo dei download di circa il 66% dal picco e costi di inferenza riportati nell'ordine di 15 milioni di dollari al giorno; l'API resta attiva fino al 24 settembre 2026.¹³ La raccomandazione condivisa è di *non* avviare nuove pipeline su Sora.¹¹

Il gruppo di testa attuale ruota attorno a pochi nomi. **Kling 3.0** (Kuaishou) è tra i leader: nativo 4K, modalità multi-shot, audio e lip-sync, clip fino a circa 15 secondi e un costo competitivo intorno a 0,10 \$/secondo.¹¹³⁰ **Google Veo 3.1** è il "tuttofare" più completo: forte aderenza al prompt, 4K, e soprattutto generazione audio nativa a 48 kHz con dialoghi in lip-sync in un solo passaggio, cosa che nessun altro fa allo stesso livello.¹¹ **Seedance 2.0** (ByteDance) produce qualità altissima ma è gravato da problemi legali (vedi 4.6) e ha avuto il rollout globale sospeso.¹³ **HappyHorse 1.0** (Alibaba) compare in cima ad Artificial Analysis con lip-sync in 7 lingue, mentre **Runway Gen-4.5** resta il preferito dai professionisti per il controllo fine (motion brush, movimenti di camera, coerenza dei personaggi).¹¹ Completano il quadro **Luma Ray3** (HDR), **Wan 2.7** (Alibaba, su pesi aperti) e **LTX-2.3** (audio stereo).¹¹

Tabella 5 — Panoramica video 2026. I punteggi provengono da arene diverse e **non sono confrontabili tra loro**; servono solo a collocare i modelli nella rispettiva classifica.¹¹¹²¹³

Modello	Produttore	Punto di forza	Riferimento
Kling 3.0	Kuaishou	4K, multi-shot, audio/lip-sync, ~0,10 \$/s	Top tier (più arene)
Veo 3.1	Google	Tuttofare; audio nativo 48 kHz in lip-sync	Top tier
Seedance 2.0	ByteDance	Qualità massima; nodi legali	ELO ~1213-1268
HappyHorse 1.0	Alibaba	Lip-sync 7 lingue; vertice AA	Top AA
Runway Gen-4.5	Runway	Controllo fine, motion brush	Pro favorite
Sora 2	OpenAI	Dismesso; API fino al 24/09/2026	In uscita

Un dato che orienta la scelta: l'asse decisivo non è più la risoluzione (ormai tutti i modelli seri fanno 1080p o 4K nativo), ma capacità come l'audio sincronizzato e il dialogo in lip-sync.¹¹ In pratica: per il dialogo parlato di qualità si va su Veo 3.1; per clip 4K social multilingua e budget contenuto su Kling 3.0; per il controllo da "film" su Runway Gen-4.5.¹¹

4.5 Generazione di audio: musica e voce

Il dominio audio si divide in due rami: **musica** e **voce**.

Nella **musica**, **Suno** (versione 5) è il riferimento di qualità, con un ELO intorno a 1293 e output a 44,1 kHz: ciò che lo distingue sono le voci, capaci di sussurri, vibrato e respiro con un realismo notevole.¹⁶ **Udio** è lo strumento del "produttore": uscita a 48 kHz, *in-painting* (rigenerare una singola sezione di un brano) e separazione degli stem, il che lo rende vicino a una vera workstation audio.¹⁶ **ElevenLabs Music**, lanciato nell'agosto 2025, ha puntato su un fattore diverso: addestramento su dati con licenza e quindi *pulizia legale* per l'uso commerciale, oltre a un realismo vocale tra i migliori in assoluto.¹⁸ Si affiancano **Google Lyria 3** (febbraio 2026) e **MiniMax Music 2.5** (gennaio 2026), che hanno colmato rapidamente il divario aggiungendo capacità vocali, più alternative come Stable Audio e Riffusion.¹⁶

Nella **voce** (sintesi vocale e clonazione), **ElevenLabs** è il leader riconosciuto, con il punteggio di similarità di clonazione più alto dei dataset di settore (9,2 su 10) e prestazioni di vertice su realismo, gamma emotiva e latenza.²⁰ Per esigenze specifiche emergono Resemble AI (gestione di voci personalizzate nel tempo), Play.ht (localizzazione), Murf (voiceover aziendali) e Descript (editing e overdub).²⁰

4.6 Il nodo trasversale: copyright e licenze

Un tema attraversa tutte le modalità: la **proprietà intellettuale**. Sul video, Seedance 2.0 ha sospeso il rollout globale a metà marzo 2026 dopo diffide (cease-and-desist) da Disney, Paramount, Warner Bros. e dalla Motion Picture Association.¹³ Sulla musica, Udio ha attraversato una transizione di licenze a fine 2025, con accordi con Universal Music Group (ottobre) e Warner Music (novembre) e download temporaneamente disabilitati durante il passaggio.¹⁷ Non a caso, gli operatori che hanno scelto fin dall'inizio dati di ad-

destramento con licenza — ElevenLabs Music su tutti — vengono indicati come l'opzione "sicura" per l'uso commerciale.¹⁸ Per chiunque debba usare contenuti generati in ambito professionale, la verifica delle condizioni di licenza del singolo strumento è oggi parte integrante del lavoro.¹⁹

5 Sviluppi futuri e ottimizzazioni: il 2027 e oltre

Cosa aspettarsi nei prossimi due-tre anni? Dalle direzioni di ricerca e dalle previsioni di settore emergono alcune linee piuttosto nette.

Convergenza in modelli multimodali unici

La tendenza più forte, già osservabile, è la fusione di testo, immagini, audio e video in **systemi unici** che ragionano e compongono in un solo passaggio, superando la separazione tra "modello linguistico" e "modello visivo".¹⁰ Entro circa un anno questa distinzione potrebbe diventare funzionalmente priva di senso.¹⁰ Una conseguenza pratica annunciata è la *memoria persistente dello stile*: modelli che imparano nel tempo le preferenze estetiche e il linguaggio visivo di un marchio o di un utente.¹⁰

Modelli specifici di dominio

Secondo Gartner, entro il 2027 oltre il **50% dei modelli di IA generativa** usati dalle aziende sarà specifico di un settore o di una funzione di business, contro circa l'1% del 2023.²¹ I modelli di dominio sono più piccoli, meno costosi da eseguire e riducono il rischio di allucinazioni rispetto ai modelli generalisti.²¹ È la direzione naturale anche per ambiti verticali come l'automazione industriale.

Modelli del mondo (world models)

Una frontiera particolarmente rilevante per la robotica e l'automazione è quella dei **world models**: modelli generativi che fungono da simulatori interni dell'ambiente. "Immaginando" le conseguenze delle proprie azioni, un agente (per esempio un robot) può pianificare e anticipare gli esiti senza interagire ogni volta con il mondo reale.³² La ricerca recente li applica al controllo in tempo reale e alla previsione del rischio in robotica, e alla realtà aumentata "generativa", in cui l'intera scena viene risintetizzata da un motore generativo.³² È un'area dove la generazione visiva incontra direttamente il controllo di macchine fisiche.

Generazione in tempo reale e comprensione della fisica

Due ottimizzazioni tecniche guideranno la qualità. La prima è la **generazione in tempo reale**, a bassa latenza e interattiva, necessaria sia per applicazioni creative sia per il controllo di sistemi.³² La seconda è la **comprensione della fisica**: i benchmark hanno iniziato a quantificare i limiti dei modelli video sui cambiamenti dinamici degli attributi (dove molti modelli ottengono punteggi bassi, tra l'8% e il 29%), e questa è indicata come la prossima vera frontiera competitiva, attesa al centro delle classifiche 2027.¹³

Efficienza, costi e sostenibilità

La vicenda Sora — dismesso anche per costi di inferenza insostenibili¹³ — segnala che l'efficienza non è un dettaglio. Aspettiamoci modelli più piccoli e specializzati, prezzi per

token in calo costante e una crescente attenzione al rapporto qualità/costo, già oggi un criterio di scelta centrale tanto quanto il punteggio grezzo.²³

SINTESI: COSA ASPETTARSI ENTRO IL 2027

- Sistemi multimodali unici che fanno testo, immagini, audio e video insieme;
- oltre metà dei modelli aziendali specifici per settore/funzione;
- maturazione dei *world models* per robotica, pianificazione e realtà aumentata;
- video più lunghi e coerenti, con la *fisica* come nuovo metro di giudizio;
- generazione in tempo reale, costi in discesa e quadro legale sulle licenze più definito.

▪ Conclusioni

La distinzione di partenza — IA generativa contro non generativa — è una linea netta e utile: la prima crea contenuti, la seconda riconosce e prevede. Il punto più sottile, e quello che spesso genera confusione, è che **i chatbot non stanno dall'altra parte di quella linea**: sono anch'essi generativi. La differenza che si percepisce tra "fare una domanda a un'IA" e "chiedere a un'IA di disegnare" è una differenza di *motore* — autoregressivo contro diffusione — e proprio quel confine, nel 2026, si sta dissolvendo a favore di modelli unici.

Lo stato dell'arte, letto attraverso le arene a voto umano, racconta un vertice affollato e in rapidissima evoluzione, in cui i nomi cambiano di mese in mese e i numeri vanno presi come istantanee. Per chi lavora con queste tecnologie, le due competenze che restano stabili sono: saper **scrivere buoni prompt** (le appendici che seguono) e saper **verificare licenze e affidabilità** prima di mettere un output in produzione. Verso il 2027, la convergenza multimodale, i modelli di dominio e i world models per la robotica sono le direzioni su cui vale la pena tenere lo sguardo.

A Appendice · I migliori prompt per le immagini

Non esiste un "prompt magico" universale, ma esiste una **struttura** che funziona in modo trasversale su Midjourney, GPT Image, Nano Banana, Flux e altri. Gli esempi qui sotto sono modelli originali costruiti sui pattern documentati dalle fonti; usateli come schema da adattare.

I principi che fanno la differenza

- **Soggetto prima dello stile.** Le prime parole pesano di più: descrivete *cosa* c'è nell'immagine prima di *come* deve apparire. Invertendo l'ordine, il modello tende a perdere il focus sul contenuto.²⁶
- **Vocabolario fotografico per il fotorealismo.** Termini come "35mm film", "85mm", "golden hour", "shallow depth of field", "medio formato Hasselblad" sono il modo più efficace per ottenere risultati realistici, perché i modelli sono stati addestrati su didascalie fotografiche.²⁶
- **Struttura a blocchi.** Soggetto → Stile/medium → Composizione (inquadratura, angolo) → Illuminazione → Dettagli (texture, colori, atmosfera).²⁷
- **Parametri (Midjourney).** `--ar` rapporto d'aspetto, `--style raw` riduce la stilizzazione di default per massimo realismo, `--v` versione del modello.²⁸
- **Identity locking per i ritratti.** Per mantenere coerenti i volti, riferirsi esplicitamente alla conservazione dei tratti ("exact facial features preserved").²⁸
- **Formato strutturato/JSON.** Per il controllo fine di prodotti e scene complesse, alcuni creator usano prompt in formato JSON con campi espliciti.²⁸

Esempio 1 — Ritratto fotorealistico

Soggetto in apertura, poi stile editoriale e parametri ottici.

```
Soggetto: A woman in her 40s working at a wooden desk, looking at the camera with a calm expression.
Stile: editorial lifestyle photography, natural warm light from a window on the left.
Ottica/composizione: shot on 85mm, shallow depth of field, slight three-quarter angle.
Dettagli: soft golden hour tones, realistic skin texture, clean blurred background. --ar 3:4 --style raw
```

Esempio 2 — Immagine di prodotto

Tipico per e-commerce e marketing; luce da studio e fondo pulito.

```
Soggetto: A matte black stainless-steel water bottle standing on a concrete surface.
Stile: professional product photography, studio lighting with soft fill.
Composizione: centered, eye-level, generous negative space above.
Dettagli: subtle reflections, ultra-detailed surface texture, neutral grey backdrop, 8K.
--ar 1:1
```

Esempio 3 — Paesaggio cinematografico

Soggetto: A lone lighthouse on a rocky cliff above a stormy sea at dusk.
Stile: cinematic, dramatic atmosphere, volumetric light.
Composizione: wide shot, low angle, rule-of-thirds.
Dettagli: crashing waves, moody blue-grey palette, fine mist, anamorphic feel. --ar 16:9

Esempio 4 — Illustrazione / concept art

Soggetto: A cozy mountain cabin interior with a fireplace and a sleeping cat.
Stile: warm storybook illustration, soft painterly brushwork.
Composizione: isometric view, balanced layout.
Dettagli: amber lighting, rich wood textures, pastel accents, hand-drawn look. --ar 4:3

Esempio 5 — Vista esplosa tecnica (utile in ambito ingegneristico)

Pattern "exploded view" molto usato per documentazione e schede prodotto.²⁸

Soggetto: Hyperrealistic 3D exploded view of a small electric gear motor, components separated along a central axis.
Stile: technical render, clean studio lighting.
Composizione: each part frozen mid-air in clear spatial separation, dramatic angles.
Dettagli: ultra-detailed metal and plastic textures, neutral background, 8K, no text. --ar 1:1

B Appendice · I migliori prompt per i video

Un prompt video **non** è un prompt per immagini con il tasto play. I modelli del 2026 (Veo 3.1, Kling 3.0, Seedance 2.0, Runway Gen-4.5) rispondono a un linguaggio specifico: tipo di movimento di camera, direzione della luce, tono emotivo, ritmo, inquadratura. Un prompt scritto "da fotografia" produce una clip sfocata e alla deriva; uno scritto "da regia" produce qualcosa che sembra una vera produzione.²⁹

La struttura che funziona

Schema raccomandato:³¹

```
[Movimento/stile di camera] + [Scena/ambiente] + [Soggetto] + [Azione/movimento] + [Illuminazione/atmosfera] + [Specifiche tecniche: durata, risoluzione, audio]
```

- **Nomi precisi dei movimenti di camera.** "dolly in", "tracking shot", "crane up", "orbit", "push-in", "aerial". Evitate termini vaghi come "dinamico" o "cinematografico" senza specificare cosa significano.²⁹
- **Riferimenti alle lenti.** "anamorphic", "85mm", "fisheye" rendono il risultato più prevedibile.²⁹
- **Direzione, temperatura e qualità della luce.** La direzione della luce cambia l'atmosfera più di ogni altro elemento: "golden hour da sinistra" è diverso da "luce diffusa di cielo coperto".³⁰
- **Punti di arrivo del movimento.** Specificare dove finisce un movimento ("then settles back into place") riduce i fallimenti e la deriva.²⁹
- **Un solo movimento per inquadratura** e indicazione esplicita di durata e risoluzione (anche "4K"/"8K" aiuta il livello di dettaglio puntato dal modello).³⁰
- **Audio e dialogo.** Su modelli con audio nativo (Veo 3.1), il dialogo va inserito breve e naturale; le scene mute possono avere segnali sonori leggeri ("distant rain", "city hum").³⁰

Esempio 1 — Establishing shot cinematografico

Sweeping aerial shot over a misty mountain range at golden hour. The camera slowly pushes forward, revealing a hidden valley with a winding river below. Volumetric fog, warm sunlight filtering through clouds, 4K cinematic, shallow depth of field at the edges. No cuts, smooth gentle movement.

Esempio 2 — Tracking a livello del soggetto

Low-angle tracking shot through a dense bamboo forest. The camera glides smoothly at waist height, bamboo stalks passing on both sides, then settles into a slow stop. Dappled sunlight, gentle breeze causing slight movement, green and gold palette, anamorphic lens flare. 8 seconds.

Esempio 3 — Azione di un personaggio

Dynamic tracking shot following a runner from behind through a futuristic city street at dusk, leaping over obstacles. Realistic cloth and hair movement, neon reflections on wet asphalt, high-energy cinematic style. Camera keeps a steady distance, then pulls back slightly at the end.

Esempio 4 — Product reveal (marketing)

A 12-second product reveal of a wristwatch on a dark stone surface, rotating slowly under soft studio reflections. Camera does a slow orbit around the watch, clean background, shallow depth of field, no text, 4K.

Esempio 5 — Scena industriale / tecnica (vicina al settore automazione)

Le interazioni e la fisica esplicite riducono l'ambiguità del movimento.²⁵

Slow push-in on a robotic arm assembling a small metal component on a clean factory line. Smooth, precise mechanical motion with accurate physics, soft industrial lighting from above, cool neutral palette. Close-up on the gripper picking up the part, then settling. Subtle machine hum. 6 seconds, 4K.

FLUSSO DI LAVORO CONSIGLIATO

Le guide concordano su un ciclo pratico: concept in una frase → espansione con lo schema sopra (50-100 parole) → generazione su 2-3 modelli diversi → confronto su qualità del movimento, coerenza e atmosfera → rifinitura del prompt → montaggio finale. Non "sposate" un solo modello: lo strumento giusto dipende dall'inquadratura.³¹

▪ Bibliografia e fonti

Fonti consultate tra maggio e giugno 2026. Le classifiche online si aggiornano in continuo: i dati citati sono istantanee riferite alle date indicate nel testo.

1. Toloka — *History of generative AI*. toloka.ai/blog/history-of-generative-ai
2. J. Canary, *A Brief History and Overview of Generative Models in Machine Learning*, Medium. medium.com/@jimcanary
3. GeeksforGeeks — *Generative AI vs. Discriminative AI*. [geeksforgeeks.org](https://www.geeksforgeeks.org)
4. Coursera — *Discriminative vs. Generative Models: What's the Difference?* coursera.org/articles/discriminative-vs-generative-models
5. Plain Concepts — *Discriminative AI vs Generative AI*. plainconcepts.com/discriminative-ai-vs-generative-ai
6. Artificial Analysis — *Text to Image Leaderboard* (aprile 2026). artificialanalysis.ai/image/leaderboard/text-to-image
7. Arena.ai (ex LMArena) — *Text-to-Image Leaderboard* (maggio 2026). arena.ai/leaderboard/text-to-image
8. LLM-Stats — *Best AI for Image Generation* (giugno 2026). llm-stats.com/leaderboards/best-ai-for-image-generation
9. Bracai — *Best AI image models in 2026*. bracai.eu/post/best-ai-image-model
10. KEAR AI — *AI Text-to-Image Arena Leaderboard 2026*. kearai.com/leaderboard/text-to-image
11. Pinggy — *Best Video Generation AI Models in 2026*. pinggy.io/blog/best_video_generation_ai_models
12. LLM-Stats — *Best AI for Video Generation* (giugno 2026). llm-stats.com/leaderboards/best-ai-for-video-generation
13. Awesome Agents — *Video Generation Benchmarks Leaderboard 2026*. awesomeagents.ai/leaderboards/video-generation-benchmarks-leaderboard
14. Pixflow — *Best AI Video Generator in 2026*. pixflow.net/blog/best-ai-video-generator
15. Get AI Perks — *Best AI Video Generators 2026*. getai perks.com/en/blogs/44-best-ai-video-generators-2026
16. TeamDay.ai — *Best AI Music Models 2026*. teamday.ai/blog/best-ai-music-models-2026
17. Jam.com — *Best AI Music Generators in 2026*. jam.com/resources/best-ai-music-generators-2026
18. AI Magicx — *Suno vs Udio vs ElevenLabs Music (2026)*. aimagicx.com/blog/suno-vs-udio-vs-elevenlabs-music-comparison-2026
19. Digital Applied — *AI Music Generation 2026*. digitalapplied.com/blog/ai-music-generation-platforms-suno-udio-elevenlabs-2026
20. DIY AI — *Best AI Voice and Audio Tools 2026*. diyai.io/ai-tools/audio-generation/best-ai-audio-tools
21. Gartner — *3 Bold and Actionable Predictions for the Future of GenAI*. gartner.com/en/articles/3-bold-and-actionable-predictions-for-the-future-of-genai
22. LMArena — *May 2026 snapshot / tracker*. agileleadershipdayindia.org (LMArena tracker)
23. ClickRank — *LLM Leaderboard 2026*. clickrank.ai/llm-leaderboard
24. OpenLM.ai — *Chatbot Arena + (metodologia ELO)*. openlm.ai/chatbot-arena
25. Magic Hour — *Cinematic AI Video Prompt Cookbook (2026)*. magichour.ai/blog/cinematic-ai-video-prompt-cookbook
26. Buffer — *The 9 Best AI Image Generators of 2026*. buffer.com/resources/ai-image-generator
27. AI Prompt Library — *50+ AI Image Generation Prompts (2026)*. aipromptlibrary.app/blog/ai-prompts-for-image-generation
28. Prompt Refinery — *Top AI Image Generation Prompts 2026*. promptrefinery.ai/ai-image-generation-prompts-2026
29. Amara (Medium) — *AI Video Prompts: Complete List (2026)*. medium.com/@aitooldiscovery

30. Tona.AI — *50+ Best AI Video Prompts for Kling, Veo & Sora 2026*. tonaai.io/blog/best-ai-video-prompts-guide-2026
31. VO3 AI — *How to Prompt Sora 2 Pro, Kling & Veo 3*. vo3ai.com (prompting guide)
32. F. Bu et al., *SEGAR: Selective Enhancement for Generative Augmented Reality*, e lavori correlati sui generative world models (1X World Model, MinD), arXiv. arxiv.org/pdf/2603.24541